Avaliação de Estratégias de Aumento de Dados na MobileNetV3-Large para Classificação de Alterações Foliares em Algodoeiro

Autor omitida[1]

[1]Instituição omitida

Abstract. *This work evaluates different data augmentation strategies for the MobileNetV3-Large architecture in the classification of foliar alterations in cotton plants associated with whitefly. Two experiments were conducted using the AgriPK dataset, differing in the application of data augmentation before or after dataset division. The results showed that the strategy influenced classification performance, particularly for minority classes. On the preserved test set, the second experiment achieved a Weighted F1-Score of 0.93, compared with 0.89 in the first.*

Resumo. *Este trabalho avalia diferentes estratégias de aumento de dados na arquitetura MobileNetV3-Large para a classificação de alterações foliares em algodoeiro associadas à mosca-branca. Foram realizados dois experimentos com o dataset AgriPK, diferenciados pela aplicação do aumento de dados antes ou após a divisão do conjunto. Os resultados mostraram que a estratégia influenciou o desempenho da classificação, principalmente nas classes minoritárias. No conjunto de teste preservado, o segundo experimento apresentou F1-Score ponderado de 0,93, enquanto o primeiro obteve 0,89.*

1. Introdução

A mosca-branca é uma praga que afeta diversas culturas. No algodoeiro, alimenta-se da seiva da planta, podendo causar danos à cultura [da Silva et al. 2023]. Além disso, atua como vetor de vírus associados à doença do enrolamento das folhas do algodoeiro (CLCuD), que pode provocar alterações foliares, redução do crescimento e perdas na produtividade [Rahman et al. 2017, Naqvi et al. 2019]. O manejo da mosca-branca envolve o Manejo Integrado de Pragas (MIP), no qual o monitoramento da população do inseto e a identificação da intensidade da infestação são etapas importantes [Ellsworth and Martinez-Carrillo 2001]. Entretanto, a avaliação em campo depende de amostragens e inspeções realizadas por pessoal treinado, tornando o processo trabalhoso e sujeito a variações relacionadas à experiência do avaliador [Feng et al. 2024].

Nesse contexto, técnicas de visão computacional e aprendizado profundo podem ser utilizadas na classificação automatizada de alterações foliares em plantas [Memon et al. 2022]. Em modelos de classificação de imagens, o aumento de dados (*data augmentation*) pode ampliar a representatividade das classes e contribuir para o treinamento de modelos em conjuntos de dados desbalanceados. Entretanto, diferentes estratégias de aplicação podem produzir resultados distintos. Ameen et al. [Ameen et al. 2023] demonstraram que a forma e o momento de aplicação do aumento de dados podem influenciar o desempenho obtido na avaliação do modelo.

Diante disso, este trabalho busca avaliar o impacto de diferentes estratégias de aplicação do *data augmentation* no desempenho da arquitetura MobileNetV3-Large, que apresenta uma estrutura eficiente e busca equilibrar acurácia e latência computacional [Howard et al. 2019], na classificação de alterações foliares em algodoeiro causada pela mosca branca.

2. Trabalhos Relacionados

O uso de *data augmentation* em tarefas de classificação de imagens tem sido investigado como uma estratégia para ampliar a quantidade e a diversidade dos dados utilizados no treinamento de modelos de aprendizado profundo. Lei et al. [Lei et al. 2019] investigaram o efeito de diferentes estratégias de *data augmentation* na classificação de imagens, considerando métodos, taxas de aplicação e combinações de transformações. Os resultados mostraram que o impacto do aumento de dados varia conforme a estratégia utilizada e que maiores quantidades de dados aumentados não necessariamente resultam em melhores desempenhos.

Dourado Filho e Calumby [Filho and Calumby 2022] avaliaram diferentes políticas de *data augmentation* em uma tarefa de reconhecimento de plantas, considerando também o desbalanceamento entre classes. Os autores compararam diferentes formas de aplicação das transformações e observaram que seus efeitos variam conforme as características das imagens e a distribuição das classes.

Hussain et al. [Hussain et al. 2018] compararam oito técnicas de *data augmentation* em uma tarefa de classificação de imagens e observaram diferenças no desempenho obtido entre as estratégias avaliadas, evidenciando que a escolha das transformações pode influenciar os resultados da classificação.

Embora esses trabalhos avaliem diferentes estratégias de *data augmentation*, este trabalho se diferencia ao analisar seu impacto na arquitetura MobileNetV3-Large para a classificação de alterações foliares em algodoeiro, comparando a aplicação do aumento de dados antes e após a divisão dos dados e seus efeitos sobre o desempenho das classes e o desempenho global do modelo.

3. Materiais e Métodos

O trabalho foi desenvolvido no Google Colab com GPU NVIDIA T4. Foi utilizado o dataset público AgriPK (Whitefly Affected Leaves), composto por quatro classes: *healthy*, *mild*, *nutrient deficiency* e *severe* [Jajja 2021]. A base apresenta desbalanceamento entre as classes, permitindo avaliar o efeito do *data augmentation* no balanceamento. Foram realizados dois experimentos utilizando a arquitetura MobileNetV3-Large, diferenciados pela ordem de aplicação do *data augmentation*.

No Experimento 1, os dados foram inicialmente divididos em treinamento, validação e teste, sendo o *data augmentation* aplicado exclusivamente ao conjunto de treinamento. No Experimento 2, o *data augmentation* foi aplicado antes da divisão dos dados, fazendo com que imagens aumentadas fossem distribuídas entre treinamento e teste. Nesse experimento, não foi utilizado um conjunto de validação, pois a divisão adicional dos dados reduziria a quantidade de imagens disponíveis para treinamento, especialmente nas classes minoritárias. Além disso, o aumento dessas classes deve ser

controlado, pois a geração excessiva de imagens pode aumentar a semelhança entre os exemplos e favorecer o *overfitting*. Assim, optou-se por utilizar mais imagens no treinamento e manter a comparação com o Experimento 1. Primeiramente, o Experimento 2 foi avaliado utilizando o conjunto de teste com imagens aumentadas. Em seguida, foi realizada uma segunda avaliação utilizando o mesmo conjunto de teste original do Experimento 1. Dessa forma, foram realizadas duas avaliações no Experimento 2, permitindo comparar o desempenho do modelo nas duas condições.

3.1. Preparação dos Dados

O dataset original possui 5.135 imagens, distribuídas em *healthy* (2.213), *mild* (280), *nutrient deficiency* (235) e *severe* (2.407).

No Experimento 1, as imagens foram divididas em treinamento, validação e teste na proporção de 70%/20%/10%. Posteriormente, as classes majoritárias foram reduzidas para 750 imagens e as minoritárias aumentadas para 750 imagens por meio de *data augmentation*, aplicado somente ao treinamento. Os conjuntos de validação e teste foram preservados sem aumento de dados e exclusão.

No Experimento 2, o balanceamento foi realizado antes da divisão dos dados. As classes majoritárias foram reduzidas para 878 imagens e as minoritárias aumentadas para 878 imagens. Em seguida, as imagens foram divididas aleatoriamente em aproximadamente 85% para treinamento e aproximadamente 15% para teste. Assim, imagens geradas por *data augmentation* também poderiam estar presentes no conjunto de teste.

As transformações foram utilizadas incluíram rotações aleatórias, variações de brilho para simular diferentes condições de iluminação, como dias nublados e ensolarados, e inversões horizontal e vertical.

3.2. Arquitetura e Treinamento da MobileNetV3-Large

A arquitetura MobileNetV3-Large foi selecionada por apresentar uma estrutura eficiente, buscando um equilíbrio entre acurácia e latência computacional [Howard et al. 2019]. As imagens foram redimensionadas para 224×224 pixels e processadas em formato RGB. O modelo foi inicializado com pesos pré-treinados no ImageNet, utilizando $\alpha = 1{,}0$, a configuração completa da arquitetura (*minimalistic=False*) e *Global Average Pooling*. A camada de classificação original foi removida e substituída por uma camada *Dense* com quatro neurônios e função de ativação *softmax*, correspondente às quatro classes do conjunto de dados.

O treinamento foi realizado em duas fases. Na primeira fase, o *backbone* da MobileNetV3-Large permaneceu congelado, sendo treinada apenas a camada de classificação durante 15 épocas, utilizando o otimizador Adam com taxa de aprendizado de $0{,}001$ e função de perda *categorical crossentropy*. Na segunda fase, o *backbone* foi descongelado para a realização do *fine-tuning*. O modelo foi recompilado com o mesmo otimizador e função de perda, porém com a taxa de aprendizado reduzida para 1×10^{-5}, e treinado por até 100 épocas.

Em ambas as fases, foi utilizado tamanho de lote (*batch size*) de 32 imagens. No Experimento 1, foram aplicados os *callbacks Early Stopping* e *ReduceLROnPlateau*, monitorando a *val_loss*, com paciência de 10 e 5 épocas, respectivamente. O *ReduceLROnPlateau* reduziu a taxa de aprendizado por um fator de $0{,}2$, até 1×10^{-6}, e o *Early*

Stopping restaurou os melhores pesos. No Experimento 2, não houve validação nem esses *callbacks*, pois dependiam da *val_loss*. Para garantir a mesma quantidade de treinamento, ambos foram executados por 10 épocas em cada fase de *fine-tuning*.

4. Resultados e Discussão

A avaliação quantitativa foi realizada com 513 imagens refente aos 10% do conjunto de teste do Experimento 1, utilizando as métricas Precision, Recall, F1-Score e Weighted Avg. As Figuras 1 e 2 apresentam os resultados dos dois experimentos.

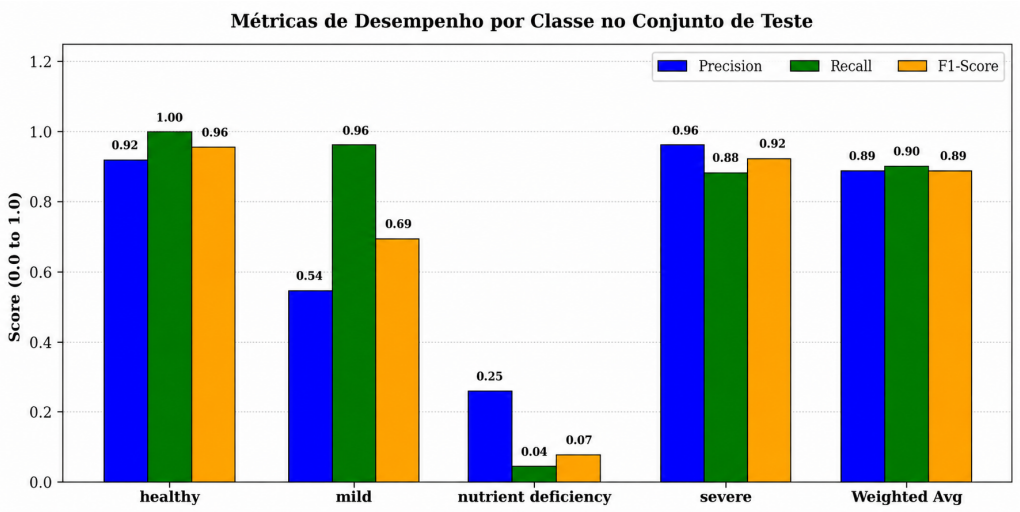


Figura 1. Métricas de Precision, Recall e F1-Score obtidas para cada classe e para o Weighted Avg no conjunto de teste do Experimento 1.

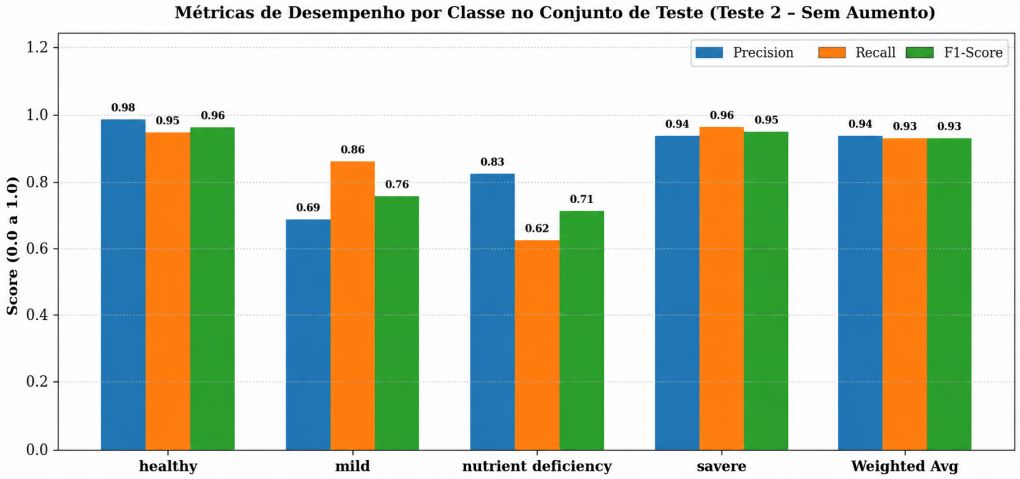


Figura 2. Métricas de Precision, Recall e F1-Score obtidas para cada classe e para o Weighted Avg no conjunto de teste do Experimento 2.

No Experimento 1, as classes *healthy* e *severe* apresentaram F1-Score de 0,96 e 0,92, respectivamente. A classe *mild* obteve Recall de 0,96 e F1-Score de 0,69, enquanto *nutrient deficiency* apresentou o menor desempenho, com Precision de 0,25, Recall de

0,04 e F1-Score de 0,07. O desempenho global foi de 0,89 em Precision, 0,90 em Recall e 0,89 em F1-Score.

No Experimento 2, utilizando o conjunto de teste original, o desempenho global aumentou para 0,94 em Precision, 0,93 em Recall e 0,93 em F1-Score. As classes *healthy* e *severe* apresentaram F1-Score de 0,96 e 0,95, enquanto *mild* alcançou 0,76. O maior avanço ocorreu em *nutrient deficiency*, cujo F1-Score passou de 0,07 para 0,71.

Como análise complementar, o Experimento 2 foi avaliado com imagens de teste submetidas ao *data augmentation*. Nesse caso, o *Weighted Avg* apresentou Precision de 0,83, Recall de 0,80 e F1-Score de 0,79. Em comparação ao conjunto original, o F1-Score de *healthy* passou de 0,96 para 0,92, *mild* aumentou de 0,76 para 0,80, *nutrient deficiency* reduziu de 0,71 para 0,64 e *severe* apresentou a maior redução, de 0,95 para 0,79.

Assim, o conjunto de teste original apresentou melhor desempenho global, com F1-Score de 0,93, enquanto a avaliação com imagens aumentadas obteve 0,79. Os resultados indicam que, neste experimento, a preservação do conjunto de teste original foi mais adequada para a avaliação do modelo.

5. Conclusão

Este trabalho avaliou o impacto de diferentes estratégias de aplicação do *data augmentation* no desempenho da arquitetura MobileNetV3-Large para a classificação de alterações foliares em algodoeiro. Os resultados demonstraram que a estratégia utilizada influencia o desempenho do modelo, tanto nas métricas globais quanto no comportamento das diferentes classes.

A avaliação também mostrou a importância de considerar o desbalanceamento do conjunto de dados, principalmente nas classes minoritárias. Para o conjunto utilizado neste trabalho, o Experimento 2 apresentou os resultados mais adequados quando avaliado no conjunto de teste original, com F1-Score ponderado de 0,93, superior aos 0,89 obtidos no Experimento 1. Além disso, houve uma melhora significativa na classe nutrient deficiency, cujo F1-Score passou de 0,07 para 0,71. Esses resultados indicam que, neste conjunto de dados, a forma de aplicação do data augmentation utilizada no Experimento 2 foi mais adequada para lidar com o desbalanceamento das classes e melhorar o desempenho do modelo.

Como trabalhos futuros, pretende-se avaliar outras estratégias de *data augmentation*, diferentes arquiteturas de redes neurais e conjuntos de dados, buscando verificar a consistência dos resultados em diferentes cenários de classificação de imagens.

6. Declaração de Uso de Inteligência Artificial

Durante a elaboração deste trabalho, foi utilizada a ferramenta de Inteligência Artificial Generativa ChatGPT, da OpenAI, para auxiliar na revisão textual e na formatação do documento em LaTeX. O conteúdo científico, a análise dos resultados e as decisões apresentadas no trabalho foram elaborados e revisados pelos autores, que são responsáveis pelo conteúdo final, em conformidade com a Portaria nº 2.664.

Referências

Ameen, Y. A., Badary, D. M., Abonnoor, A. E. I., Hussain, K. F., and Sewisy, A. A. (2023). Which data subset should be augmented for deep learning? a simulation study using urothelial cell carcinoma histopathology images. *BMC Bioinformatics*, 24:75.

da Silva, B. G., Corrêa, F. R., da Silva, N. F., da S. Cavalcante, W. S., Ribeiro, D. F., and Rodrigues, E. (2023). Controle químico de mosca-branca (*Bemisia tabaci*) biotipo b (hemiptera: Aleyrodidae) na cultura do algodão. *Brazilian Journal of Science*, 2(2):86–97.

Ellsworth, P. C. and Martinez-Carrillo, J. L. (2001). Ipm for *Bemisia tabaci*: A case study from north america. *Crop Protection*, 20(9):853–869.

Feng, Z., Wang, N., Jin, Y., Cao, H., Huang, X., Wen, S., and Ding, M. (2024). Enhancing cotton whitefly (*Bemisia tabaci*) detection and counting with a cost-effective deep learning approach on the raspberry pi. *Plant Methods*, 20:161.

Filho, L. A. D. and Calumby, R. T. (2022). Data augmentation policies and heuristics effects over dataset imbalance for developing plant identification systems based on deep learning: A case study. *Revista Brasileira de Computação Aplicada*, 14(2):85–94.

Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., Le, Q. V., and Adam, H. (2019). Searching for mobilenetv3. In *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1314–1324, Seoul, Korea (South).

Hussain, Z., Gimenez, F., Yi, D., and Rubin, D. (2018). Differential data augmentation techniques for medical imaging classification tasks. In *AMIA Annual Symposium Proceedings*, pages 979–984.

Jajja, A. I. (2021). Agripk dataset for whitefly affected leaves. Kaggle Dataset.

Lei, C., Hu, B., Wang, D., Zhang, S., and Chen, Z. (2019). A preliminary study on data augmentation of deep learning for image classification. In *Proceedings of the 11th Asia-Pacific Symposium on Internetware*, pages 1–6.

Memon, M. S., Kumar, P., and Iqbal, R. (2022). Meta deep learn leaf disease identification model for cotton crop. *Computers*, 11:102.

Naqvi, R. Z., e. A. Zaidi, S. S., Mukhtar, M. S., Amin, I., Mishra, B., Strickler, S., Mueller, L. A., Asif, M., and Mansoor, S. (2019). Transcriptomic analysis of cultivated cotton *Gossypium hirsutum* provides insights into host responses upon whitefly-mediated transmission of cotton leaf curl disease. *PLoS ONE*, 14(2):e0210011.

Rahman, M., Khan, A. Q., Rahmat, Z., Iqbal, M. A., and Zafar, Y. (2017). Genetics and genomics of cotton leaf curl disease, its viral causal agents and whitefly vector: A way forward to sustain cotton fiber security. *Frontiers in Plant Science*, 8:1157.